

Fusion S2/S3 — Modèles linéaires de Tucker couplée à cœur parcimonieux

Un modèle, cinq solveurs : ce que l'optimiseur change

Hamza BOUDA

LISIC — ULCO
Point hebdomadaire d'équipe

16 juillet 2026

Contexte et objectif de la semaine

Problème : reconstruire la scène super-résolue

$\mathcal{S} \in \mathbb{R}^{H \times W \times C}$ depuis

- MSI fine spatialement ($c \ll C$ bandes) — rôle de S2 ;
- HSI grossière (ratio r) — rôle de S3.

Cette semaine : consolider la **famille linéaire** — même modèle de Tucker couplé sparse, **cinq algorithmes de résolution** — avant le passage au non-linéaire.

Pourquoi ?

- baseline honnête pour l'article ;
- séparer *effet du modèle* et *effet du solveur* ;
- activer réellement la parcimonie du cœur (demande centrale du sujet).

Le modèle (commun aux cinq architectures)

Décomposition de Tucker couplée, cœur parcimonieux :

$$\mathcal{S} = \mathcal{G} \times_1 \mathbf{D}_1 \times_2 \mathbf{D}_2 \times_3 \mathbf{D}_3$$

$$\min \lambda_H \|\mathcal{H} - \mathcal{S} \times_1 \mathbf{B}_h \times_2 \mathbf{B}_w\|_F^2 + \lambda_M \|\mathcal{M} - \mathcal{S} \times_3 \mathbf{R}\|_F^2 + \beta \|\mathcal{G}\|_1$$

- Attache HSI → ancre les **spectres** ; attache MSI → ancre la **géométrie fine** ;
- ℓ_1 sur $\mathcal{G}$: peu d'interactions triples (motif ligne $\times$ motif colonne $\times$ signature) ;
- Normalisation des colonnes de $\mathbf{D}_n$ = lève l'ambiguïté d'échelle, β garde un sens ;
- Initialisation SVD depuis les observations (jamais la référence).

vs prédécesseurs (G-STEREO) : CPD de rang F , coût sans ℓ_1 — notre apport : structure Tucker + parcimonie explicite du cœur.

Cinq solveurs pour le même programme

	Mise à jour	Pas	Zéros exacts	Coût/itér.
ALS+FISTA	alternée exacte	Lipschitz calculé	oui (prox)	élevé
Adam+prox	simultanée	adaptatif/coordonnée	oui (prox)	faible
Adam+ ℓ_1	simultanée	adaptatif/coordonnée	non	faible
SGD+prox	simultanée	global fixe	oui (prox)	faible
LBFGS+prox	simultanée	courbure ($m=10$)	oui (prox)	$\sim 20\times$

- Schéma **prox** : seuillage doux $S_\tau(x) = \text{sign}(x) \max(|x| - \tau, 0)$ après chaque pas — **vrais zéros** dans $\mathcal{G}$;
- Schéma **pénalité** : $\beta \text{sign}(\mathcal{G})$ dans le gradient — rétrécit sans jamais annuler ;
- Protocole identique pour tous : mêmes opérateurs PSF/SRF, même init, mêmes 6 cas (3 PSF $\times$ ratios 4/8, bruit 35/30 dB).

Résultats — 4 métriques, 2 scènes

Même modèle Tucker couplé sparse — cinq solveurs
Moyennes sur 6 cas (PSF gaussienne/Airy/sinc x ratios 4/8, SNR 35/30 dB)






Tableau récapitulatif

Méthode	Indian Pines				Pavia			
	PSNR	SAM	Q2n	ERGAS	PSNR	SAM	Q2n	ERGAS
ALS + FISTA (fermé)	10.17	22.80	0.06	16.03	12.84	20.45	0.04	19.62
ALS + FISTA (Lipschitz, v0)	15.89	15.25	0.65	8.32	17.84	14.11	0.60	10.11
Adam + prox	19.00	11.22	0.79	5.66	19.53	10.28	0.64	8.96
Adam + ℓ_1	19.00	11.22	0.79	5.66	19.53	10.27	0.64	8.96
SGD + prox	19.59	10.66	0.80	5.36	19.72	9.47	0.63	8.88
LBFGS + prox	19.08	10.97	0.82	5.54	18.67	12.10	0.59	9.93

- Moyennes sur les 6 cas du protocole (3 PSF $\times$ ratios 4/8, SNR 35/30 dB), meilleur en **gras** ;
- Même format que le tableau des méthodes MATLAB de l'équipe — comparaison directe possible dès que le protocole sera aligné (paramètres demandés).

- ❶ **Le solveur domine l'écart** — hiérarchie à trois niveaux, à modèle strictement identique : ALS à mise à jour fermée approchée (~ 12.8 dB) $\ll$ ALS à pas de Lipschitz, v0 (~ 17.8 dB) $<$ famille gradient (~ 19.5 – 19.7 dB). **Le détail d'implémentation de la mise à jour des dictionnaires vaut +5 dB** ; le passage au gradient simultané en vaut ~ 2 de plus.
- ❷ **Hiérarchie stable sur les deux scènes** : ALS $\ll$ SGD $<$ LBFGS $\approx$ Adam. Le conditionnement du problème est essentiellement *diagonal* (échelles par coordonnée) : Adam suffit, la courbure croisée de LBFGS n'apporte rien à budget égal.
- ❸ **Conséquence méthodologique** : comparer un modèle non-linéaire (entraîné par gradient) à un linéaire résolu par ALS **surestime** l'apport de la non-linéarité. Notre tableau d'article reportera les deux baselines.


Dynamique d'optimisation



- Deux phases : chute rapide (~ 150 itér., raffinement de l'init SVD) puis décroissance lente en loi de puissance ;
- Gradient : ~ 40 – 90 s par cas sur A100 — contre ~ 4 – 5 min pour l'ALS (CPU, systèmes linéaires + SVD).

Parcimonie du cœur : activer réellement le ℓ_1

Courbe parcimonie-fidélité : seuillage proximal vs pénalité L1 (Pavia, rangs 30×30×10)



- Trois régimes : **inactif** ($\beta \leq 10^{-2}$, sparsité ≈ 0), **utile** ($\beta \approx 0.1$), **mort du cœur** ($\beta \geq 1$, 100 % de zéros, effondrement) ;
- Point clé : à $\beta = 0.1$, un cœur à 45 % de zéros exacts *améliore* la fidélité (+1.4 dB PSNR, -1.7° SAM) — la parcimonie régularise, elle ne coûte pas ;
- Seul le schéma **proximal** atteint ce régime : la pénalité ℓ_1 sous-différentiée rétrécit sans annuler (sparsité = 0 partout) et s'effondre plus tard mais sans interprétabilité.

Conclusions des analyses

- 1 **Le solveur fait partie du modèle empirique** : à paramétrisation strictement identique, l'écart entre algorithmes d'optimisation atteint +7 dB — plus que ce qu'apportent la plupart des changements de modèle. Toute comparaison de modèles doit donc fixer le cadre d'optimisation.
- 2 **La famille gradient (Adam/SGD/LBFGS + prox) est le bon cadre** : meilleure fidélité sur toutes les métriques et les deux scènes, 3 à 10× plus rapide, et directement transposable au non-linéaire.
- 3 **La parcimonie du cœur est validée expérimentalement** : au bon réglage ($\beta \approx 0.1$), un cœur à 45 % de zéros exacts *améliore* la reconstruction (+1.4 dB, -1.7° SAM) — elle régularise, elle ne coûte pas. Seul le seuillage proximal atteint ce régime.

- ➊ **Réentraîner nos modèles dans les mêmes conditions d'entraînement que G-STEREO / STEREO / SCOTT** (même simulation des flux, mêmes opérateurs, mêmes métriques) pour une comparaison directe avec les méthodes de l'équipe ;
- ➋ **Sélectionner l'approche linéaire la plus performante** issue de cette étude (cadre gradient + seuillage proximal) ;
- ➌ **L'optimiser par grid search** : rangs (R_1, R_2, R_3) , poids de parcimonie β , taux d'apprentissage — avec un β adaptatif à l'échelle du cœur ;
- ➍ **Passer aux modèles non-linéaires (auto-encodeurs)** en réutilisant le même cadre : même perte couplée, mêmes opérateurs physiques, même seuillage proximal — seul le décodeur multilinéaire est remplacé par un décodeur appris.