

Modèles linéaires de fusion hyperspectrale par décomposition de Tucker couplée à cœur parcimonieux : architectures et algorithmes d’optimisation

Étude comparative de cinq stratégies de résolution du même problème inverse

Hamza BOUDA

Stage Assistant Ingénieur — Laboratoire LISIC, ULCO

Encadrement : projet fusion Sentinel-2 / Sentinel-3

Juillet 2026

Abstract

Nous décrivons en détail la famille de modèles *linéaires* développée pour la fusion d’images hyperspectrale/multispectrale (HSI–MSI), fondée sur une décomposition de Tucker couplée dont le cœur est contraint à la parcimonie. Le modèle génératif est unique ; ce qui distingue les cinq architectures présentées est la *stratégie d’optimisation* : (i) moindres carrés alternés avec étape proximale accélérée (ALS+FISTA), (ii) gradient adaptatif avec opérateur proximal découplé (Adam+prox), (iii) gradient adaptatif avec pénalité ℓ_1 sous-différentiée (Adam+ ℓ_1), (iv) gradient stochastique à inertie avec étape proximale (SGD+prox), et (v) quasi-Newton à mémoire limitée avec étape proximale (LBFGS+prox). Pour chaque variante nous donnons les équations de mise à jour complètes, les garanties théoriques, le coût par itération et le traitement exact ou approché de la contrainte de parcimonie. Nous montrons que ces choix, à modèle strictement identique, induisent des comportements très différents : l’écart entre solveurs peut dépasser l’écart entre classes de modèles, ce qui impose de séparer soigneusement contribution du modèle et contribution de l’optimiseur dans toute étude comparative.

1 Introduction

La fusion HSI–MSI vise à reconstruire une image de haute résolution à la fois spatiale et spectrale, la *super-resolution image* (SRI) $\mathcal{S} \in \mathbb{R}^{H \times W \times C}$, à partir de deux observations dégradées et complémentaires :

- une image **hyperspectrale basse résolution spatiale** $\mathcal{H} \in \mathbb{R}^{h \times w \times C}$ (riche spectralement, C bandes, grille grossière $h \times w$ avec $H/h = W/w = r$) ;
- une image **multispectrale haute résolution spatiale** $\mathcal{M} \in \mathbb{R}^{H \times W \times c}$ (fine spatialement, pauvre spectralement, $c \ll C$ bandes).

Ce problème est le cœur méthodologique de la fusion Sentinel-2/Sentinel-3 : Sentinel-2 joue le rôle du flux multispectral fin (jusqu’à 10 m, 13 bandes) et Sentinel-3/OLCI celui du flux hyperspectral grossier (300 m, 21 bandes).

Le problème est un *problème inverse mal posé* : le nombre d’inconnues ($H \cdot W \cdot C$) excède largement le nombre d’observations. Toute méthode doit donc injecter un *a priori* de structure. La famille de modèles étudiée ici adopte l’a priori multilinéaire de TUCKER : la scène vit dans le produit de trois sous-espaces de faible dimension (spatial ligne, spatial colonne, spectral), couplés par un cœur creux qui encode les interactions.

Positionnement. Ce cadre est celui des méthodes tensorielles de la littérature — STEREO (CPD couplée), SCOTT (Tucker couplée par HOSVD), et leurs variantes parcimonieuses G-STEREO/G-SCOTT. Notre contribution dans ce rapport n’est pas le modèle lui-même mais son étude à *solveur variable* : nous résolvons **le même** programme d’optimisation par cinq algorithmes de natures différentes et nous explicitons ce que chaque choix change, mathématiquement et pratiquement.

2 Notations et rappels d’algèbre multilinéaire

Les tenseurs sont notés en calligraphie grasse ($\mathcal{S}$), les matrices en gras ($\mathbf{D}$), les scalaires en italique. Pour $\mathcal{X} \in \mathbb{R}^{I_1 \times I_2 \times I_3}$:

Définition 1 (Dépliement). *Le dépliement selon le mode n , noté $\mathbf{X}_{(n)}$, réarrange les fibres de mode n en colonnes : $\mathbf{X}_{(1)} \in \mathbb{R}^{I_1 \times I_2 I_3}$, $\mathbf{X}_{(2)} \in \mathbb{R}^{I_2 \times I_1 I_3}$, $\mathbf{X}_{(3)} \in \mathbb{R}^{I_3 \times I_1 I_2}$.*

Définition 2 (Produit de mode). *Le produit de mode n entre $\mathcal{X}$ et $\mathbf{U} \in \mathbb{R}^{J \times I_n}$, noté $\mathcal{X} \times_n \mathbf{U}$, contracte la dimension I_n : $(\mathcal{X} \times_1 \mathbf{U})_{ji_2 i_3} = \sum_{i_1} U_{ji_1} X_{i_1 i_2 i_3}$, soit en dépliement $(\mathcal{X} \times_n \mathbf{U})_{(n)} = \mathbf{U} \mathbf{X}_{(n)}$.*

Définition 3 (Décomposition de Tucker). *Une décomposition de Tucker de rangs multilinéaires (R_1, R_2, R_3) s’écrit*

$$\mathcal{S} = \mathcal{G} \times_1 \mathbf{D}_1 \times_2 \mathbf{D}_2 \times_3 \mathbf{D}_3, \quad \mathcal{G} \in \mathbb{R}^{R_1 \times R_2 \times R_3}, \quad \mathbf{D}_n \in \mathbb{R}^{I_n \times R_n}, \quad (1)$$

où $\mathcal{G}$ est le cœur et les $\mathbf{D}_n$ les dictionnaires (ou facteurs) de mode. En coordonnées : $S_{ijk} = \sum_{a=1}^{R_1} \sum_{b=1}^{R_2} \sum_{c=1}^{R_3} G_{abc} (D_1)_{ia} (D_2)_{jb} (D_3)_{kc}$.

Le nombre de degrés de liberté passe de HWC à $R_1 R_2 R_3 + H R_1 + W R_2 + C R_3$ — pour Pavia ($608 \times 336 \times 103$) et des rangs $(30, 30, 10)$, c’est une compression d’un facteur ~ 700 . C’est cet écrasement dimensionnel qui rend le problème inverse identifiable.

3 Modèle d’observation

3.1 Dégradation spatiale (voie hyperspectrale)

L’acquisition basse résolution est modélisée par un flou de réponse impulsionnelle (PSF) suivi d’une décimation de facteur r , *séparable* par lignes et colonnes :

$$\mathcal{H} = \mathcal{S} \times_1 \mathbf{B}_h \times_2 \mathbf{B}_w + \mathcal{E}_H, \quad \mathbf{B}_h \in \mathbb{R}^{h \times H}, \quad \mathbf{B}_w \in \mathbb{R}^{w \times W}, \quad (2)$$

où $\mathcal{E}_H$ est un bruit blanc gaussien. La matrice $\mathbf{B}_h$ est construite depuis la coupe centrale 1-D $p \in \mathbb{R}^{2m+1}$ du noyau PSF 2-D fourni (normalisée à somme unité), par

$$(\mathbf{B}_h)_{i,j} = \frac{p_{j-ir+m}}{\sum_l p_{l-ir+m}} \quad \text{si } |j-ir| \leq m, \quad 0 \text{ sinon}, \quad (3)$$

c’est-à-dire une convolution-décimation à bords renormalisés (chaque ligne de $\mathbf{B}_h$ somme à 1, ce qui préserve la radiométrie moyenne).

3.2 Dégradation spectrale (voie multispectrale)

L’intégration des bandes fines dans les bandes larges du capteur MSI est modélisée par la matrice de réponses spectrales (SRF) $\mathbf{R} \in \mathbb{R}^{c \times C}$:

$$\mathcal{M} = \mathcal{S} \times_3 \mathbf{R} + \mathcal{E}_M. \quad (4)$$

3.3 Normalisation et cohérence d'échelle

Chaque observation est normalisée par son percentile 99 : $\tilde{\mathcal{H}} = \mathcal{H}/s_H$, $\tilde{\mathcal{M}} = \mathcal{M}/s_M$ avec $s_X = \text{perc}_{99}(\mathcal{X})$. La SRI est estimée dans l'échelle de $\mathcal{H}$; la prédiction MSI doit donc être recalée par le facteur $\rho = s_H/s_M$:

$$\widehat{\mathcal{M}} = \rho (\mathcal{S} \times_3 \mathbf{R}). \quad (5)$$

Cette correction, absente des implémentations historiques, supprime un biais systématique entre les deux termes d'attache aux données.

4 Le modèle commun : Tucker couplé à cœur parcimonieux

Toutes les architectures de ce rapport estiment le *même* objet : le quadruplet $(\mathcal{G}, \mathbf{D}_1, \mathbf{D}_2, \mathbf{D}_3)$ minimisant la fonction de coût couplée

$$\mathcal{L}(\mathcal{G}, \mathbf{D}_1, \mathbf{D}_2, \mathbf{D}_3) = \underbrace{\lambda_H \left\| \tilde{\mathcal{H}} - \mathcal{G} \times_1 \mathbf{B}_h \mathbf{D}_1 \times_2 \mathbf{B}_w \mathbf{D}_2 \times_3 \mathbf{D}_3 \right\|_F^2}_{\text{attache HSI}} + \underbrace{\lambda_M \left\| \tilde{\mathcal{M}} - \rho \mathcal{G} \times_1 \mathbf{D}_1 \times_2 \mathbf{D}_2 \times_3 \mathbf{R} \mathbf{D}_3 \right\|_F^2}_{\text{attache MSI}} \quad (6)$$

avec $\|\mathcal{G}\|_1 = \sum_{abc} |G_{abc}|$ et, dans toutes nos expériences, $\lambda_H = \lambda_M = 1$.

4.1 Rôle de chaque terme

Attache HSI. La reconstruction $\mathcal{S}$ dégradée spatialement (éq. 2) doit expliquer l'observation hyperspectrale : ce terme ancre les *spectres*. Comme $\mathbf{B}_h \mathbf{D}_1$ compose le dictionnaire spatial avec le flou, l'information spatiale fine de $\mathbf{D}_1$ n'y est pas contrainte — elle l'est par le second terme.

Attache MSI. La reconstruction projetée spectralement (éq. 4) doit expliquer l'observation multispectrale : ce terme ancre la *géométrie fine*. La complémentarité des deux projections ($\mathbf{B}$ agit sur les modes 1–2, $\mathbf{R}$ sur le mode 3) est ce qui rend le couplage identifiant : aucune observation seule ne contraint tous les modes.

Parcimonie du cœur. La pénalité ℓ_1 sur $\mathcal{G}$ est la relaxation convexe du comptage ℓ_0 . Elle repose sur l'hypothèse physique que *peu d'interactions triples* (motif spatial ligne $\times$ motif spatial colonne $\times$ signature spectrale) suffisent à décrire la scène : le cœur agit comme une table de contingence creuse entre les atomes des trois dictionnaires. Outre la régularisation statistique, la parcimonie protège contre le sur-ajustement du bruit dans le régime très sous-déterminé.

4.2 Ambiguïté d'échelle et normalisation des dictionnaires

Proposition 1 (Invariance d'échelle). *Pour toutes matrices diagonales inversibles $\mathbf{\Lambda}_n$, le remplacement $\mathbf{D}_n \leftarrow \mathbf{D}_n \mathbf{\Lambda}_n^{-1}$, $\mathcal{G} \leftarrow \mathcal{G} \times_1 \mathbf{\Lambda}_1 \times_2 \mathbf{\Lambda}_2 \times_3 \mathbf{\Lambda}_3$ laisse $\mathcal{S}$ inchangée mais modifie $\|\mathcal{G}\|_1$.*

Sans contrainte supplémentaire, l'optimiseur peut donc *contourner* la pénalité ℓ_1 en gonflant les dictionnaires et en écrasant le cœur (ou l'inverse), rendant le seuillage incohérent d'une itération à l'autre. Toutes nos architectures lèvent cette ambiguïté par la **normalisation des colonnes** :

$$\mathbf{D}_n \longleftarrow \mathbf{D}_n \text{diag}(\|\mathbf{d}_{n,1}\|_2, \dots, \|\mathbf{d}_{n,R_n}\|_2)^{-1}, \quad (7)$$

appliquée à chaque itération (ALS) ou à chaque passe avant (variantes gradient, où la normalisation est *incluse dans le graphe de calcul* et donc différenciée). Toute l'énergie vit alors dans $\mathcal{G}$, et β a une signification stable.

4.3 Initialisation par SVD des observations

Le problème (6) est non convexe ; le point de départ est décisif. Toutes les architectures partagent la même initialisation *spectrale par les données*, qui n'utilise que les observations (jamais la référence) :

$$\mathbf{D}_1^{(0)} = U_{R_1}(\widetilde{\mathbf{M}}_{(1)}), \quad \mathbf{D}_2^{(0)} = U_{R_2}(\widetilde{\mathbf{M}}_{(2)}), \quad \mathbf{D}_3^{(0)} = U_{R_3}(\widetilde{\mathbf{H}}_{(3)}), \quad (8)$$

où $U_k(\cdot)$ désigne les k premiers vecteurs singuliers gauches : les sous-espaces spatiaux viennent du flux le plus fin spatialement, le sous-espace spectral du flux le plus riche spectralement. Le cœur est initialisé par projection de l'observation fine :

$$\mathcal{G}^{(0)} = \widetilde{\mathcal{M}} \times_1 \mathbf{D}_1^{(0)\top} \times_2 \mathbf{D}_2^{(0)\top} \times_3 (\mathbf{R}\mathbf{D}_3^{(0)})^\top, \quad \mathcal{G}^{(0)} \leftarrow \mathcal{G}^{(0)} / \|\mathcal{G}^{(0)}\|_F. \quad (9)$$

5 Architecture I — ALS + FISTA (solveur de référence)

La première architecture suit la tradition des méthodes tensorielle (STEREO, SCOTT, CTF) : une **minimisation alternée par blocs**. On observe que (6), non convexe globalement, est *convexe par bloc* : à trois blocs fixés, le problème dans le quatrième est un moindre carré (éventuellement pénalisé ℓ_1). L'algorithme boucle donc sur quatre sous-problèmes résolus exactement ou quasi exactement.

5.1 Mise à jour des dictionnaires (moindres carrés)

Écrivons le résidu de la source k en dépliement de mode n : en notant $\mathbf{B}_k^{(n)}$ l'opérateur agissant sur le mode n pour la source k (p.ex. $\mathbf{B}_h$ pour la source HSI en mode 1, $\mathbf{I}$ pour la source MSI) et $\mathbf{W}_k^{(n)}$ le produit de Khatri–Rao–Kronecker des autres facteurs dégradés,

$$\mathbf{Y}_{k(n)} \approx \mathbf{B}_k^{(n)} \mathbf{D}_n \mathbf{A}_k^{(n)\top}, \quad \mathbf{A}_k^{(n)} := (\text{facteurs et cœur des autres modes}). \quad (10)$$

La mise à jour pratique de $\mathbf{D}_n$ agrège toutes les sources dans un système linéaire de type normal :

$$\left[\sum_k \lambda_k \mathbf{B}_k^{(n)\top} \mathbf{B}_k^{(n)} + \varepsilon \mathbf{I} \right] \mathbf{D}_n = \sum_k \lambda_k \mathbf{B}_k^{(n)\top} \mathbf{Y}_{k(n)} \mathbf{A}_k^{(n)}, \quad (11)$$

résolu par moindres carrés régularisés ($\varepsilon = 10^{-5}$), puis normalisation des colonnes (éq. 7). Chaque source contribue au système : le dictionnaire spatial voit à la fois la version floutée (via $\mathbf{B}^\top \mathbf{B}$) et la version fine (via $\mathbf{I}$).

5.2 Mise à jour du cœur (FISTA)

À dictionnaires fixés, le sous-problème en $\mathcal{G}$ est un LASSO tensoriel : $\min_{\mathcal{G}} f(\mathcal{G}) + \beta \|\mathcal{G}\|_1$ avec f quadratique. Son gradient s'obtient par rétro-projection des résidus :

$$\nabla f(\mathcal{G}) = 2 \sum_k \lambda_k \mathcal{R}_k \times_1 (\mathbf{B}_k^{(1)} \mathbf{D}_1)^\top \times_2 (\mathbf{B}_k^{(2)} \mathbf{D}_2)^\top \times_3 (\mathbf{B}_k^{(3)} \mathbf{D}_3)^\top, \quad (12)$$

où $\mathcal{R}_k$ est le résidu de la source k . La constante de Lipschitz de ∇f est majorée par le produit des normes spectrales :

$$L = 2 \sum_k \lambda_k \prod_{n=1}^3 \|\mathbf{B}_k^{(n)} \mathbf{D}_n\|_2^2, \quad (13)$$

ce qui donne un pas *calculé, sans réglage*. L'itération FISTA combine étape de gradient, opérateur proximal et extrapolation de Nesterov :

$$\mathcal{G}^{(j+1)} = S_{\beta/L} \left(\mathcal{Z}^{(j)} - \frac{1}{L} \nabla f(\mathcal{Z}^{(j)}) \right), \quad t_{j+1} = \frac{1 + \sqrt{1 + 4t_j^2}}{2}, \quad \mathcal{Z}^{(j+1)} = \mathcal{G}^{(j+1)} + \frac{t_j - 1}{t_{j+1}} (\mathcal{G}^{(j+1)} - \mathcal{G}^{(j)}), \quad (14)$$

où $S_\tau(x) = \text{sign}(x) \max(|x| - \tau, 0)$ est le **seuillage doux**, opérateur proximal exact de $\tau \|\cdot\|_1$. FISTA garantit $f(\mathcal{G}^{(j)}) - f^* = O(1/j^2)$ sur ce sous-problème.

5.3 Propriétés

- **Garanties** : descente monotone de $\mathcal{L}$ à chaque bloc ; convergence vers un point critique du problème joint (au sens des méthodes BCD sur fonctions multi-convexes).
- **Parcimonie exacte** : le prox produit de vrais zéros ; la sparsité de $\mathcal{G}$ est mesurable et interprétable.
- **Hyperparamètres** : quasi aucun (β , rangs, nombre d'itérations) ; le pas est déduit de (13).
- **Coût** : chaque itération externe requiert des dépliements, des systèmes linéaires $R_n \times R_n$ par bloc et $O(n_{\text{FISTA}})$ produits de mode ; c'est l'architecture la plus chère par itération (~ 265 s par scène Pavia en pratique, CPU).
- **Limite** : la résolution *exacte* de chaque bloc peut sur-adapter le bloc courant aux erreurs des blocs figés, et la trajectoire alternée peut converger vers des points critiques de mauvaise qualité — phénomène observé expérimentalement (voir §11).

6 Le cadre gradient unifié (architectures II–V)

Les quatre architectures suivantes abandonnent l'alternance : tous les paramètres $\theta = (\mathcal{G}, D_1, D_2, D_3)$ sont mis à jour *simultanément* par différentiation automatique de la partie lisse de (6),

$$f(\theta) = \lambda_H \left\| \tilde{\mathcal{H}} - \hat{\mathcal{H}}(\theta) \right\|_F^2 + \lambda_M \left\| \tilde{\mathcal{M}} - \hat{\mathcal{M}}(\theta) \right\|_F^2, \quad (15)$$

la normalisation des colonnes (7) étant à l'intérieur du graphe de calcul : on optimise des paramètres libres D_n^{raw} et le modèle utilise $D_n = D_n^{\text{raw}} / \|\cdot\|_{2,\text{col}}$, si bien que la contrainte est exactement satisfaite à chaque évaluation, sans projection externe. Les gradients sont bornés par écrêtage de norme globale ($\|\nabla\|_2 \leq 10$).

La pénalité ℓ_1 , non lisse, est traitée de deux manières concurrentes qui définissent les sous-familles *prox* et ℓ_1 -*pénalisée* :

(a) Schéma proximal (splitting avant–arrière). Après chaque pas de l'optimiseur sur f seul, on applique le prox au cœur :

$$\mathcal{G} \longleftarrow S_\tau(\mathcal{G}), \quad \tau = \beta \eta_0, \quad (16)$$

où η_0 est le **pas nominal** (et non le pas courant du scheduler) : ce *découplage* évite que la décroissance du taux d'apprentissage n'affaiblisse silencieusement le seuil effectif en fin d'entraînement. Comme en FISTA, le prox produit des **zéros exacts**.

(b) Pénalité sous-différentiée. On ajoute $\beta \|\mathcal{G}\|_1$ directement à la perte ; l'autodiff propage $\beta \text{sign}(\mathcal{G})$. Le gradient pousse les coefficients vers zéro mais, un pas de gradient étant une opération continue, **aucun coefficient n'atteint exactement zéro** : la parcimonie est approchée (coefficients $O(\beta\eta)$), non structurelle.

Remarque 1. La distinction (a)/(b) est invisible sur la fidélité lorsque β est petit (les deux variantes coïncident à 10^{-4} près dans nos mesures pour $\beta = 10^{-6}$) mais devient essentielle dès que la parcimonie est un objectif en soi : seul le schéma proximal fournit un support creux exploitable et un diagnostic fiable de la santé du cœur.

7 Architecture II — Adam + prox

L'optimiseur Adam maintient des moments d'ordre 1 et 2 par coordonnée :

$$\mathbf{m}_t = \gamma_1 \mathbf{m}_{t-1} + (1 - \gamma_1) \mathbf{g}_t, \quad \mathbf{v}_t = \gamma_2 \mathbf{v}_{t-1} + (1 - \gamma_2) \mathbf{g}_t^{\odot 2}, \quad (17)$$

$$\hat{\mathbf{m}}_t = \mathbf{m}_t / (1 - \gamma_1^t), \quad \hat{\mathbf{v}}_t = \mathbf{v}_t / (1 - \gamma_2^t), \quad (18)$$

$$\theta_{t+1} = \theta_t - \eta_t \frac{\hat{\mathbf{m}}_t}{\sqrt{\hat{\mathbf{v}}_t} + \epsilon}, \quad (\gamma_1, \gamma_2, \epsilon) = (0.9, 0.999, 10^{-8}), \quad (19)$$

suivi de l'étape proximale (16) sur $\mathcal{G}$ uniquement.

Pourquoi Adam domine-t-il sur ce problème ? Le paysage de (6) est extrêmement **mal conditionné** : les sensibilités de $\mathcal{L}$ aux coordonnées de $\mathcal{G}$ (multipliées par trois dictionnaires) et aux coordonnées des $\mathbf{D}_n$ (multipliées par le cœur et deux dictionnaires) diffèrent de plusieurs ordres de grandeur, et varient au cours de l'optimisation. La renormalisation par $\sqrt{\hat{\mathbf{v}}_t}$ agit comme un préconditionneur diagonal adaptatif qui égalise ces échelles — c'est l'analogue stochastique du pas de Lipschitz par bloc de l'ALS, mais *par coordonnée* et sans calcul de normes spectrales.

Réglage retenu (après balayage). $\eta_0 = 10^{-2}$, scheduler cosinus $\eta_t = \eta_{\min} + \frac{1}{2}(\eta_0 - \eta_{\min})(1 + \cos(\pi t/T))$, $T = 10^4$ itérations, arrêt anticipé sur la perte (patience réglable), seuil prox découplé $\tau = \beta\eta_0$.

Complexité. Une itération = une passe avant (deux produits de mode complets) + une rétropropagation ($\approx 2 \times$ la passe avant) + $O(\#\theta)$ pour Adam ; entièrement vectorisée sur GPU ($\sim 40\text{--}90$ s pour 10^4 itérations sur A100, scène Pavia).

8 Architecture III — Adam + pénalité ℓ_1

Identique à l'architecture II *sauf* le traitement de la parcimonie : la perte optimisée devient $f(\theta) + \beta \|\mathcal{G}\|_1$ et aucune étape proximale n'est appliquée. Le sous-gradient utilisé par l'autodiff est

$$\partial_{\mathcal{G}} [\beta \|\mathcal{G}\|_1] = \beta \text{sign}(\mathcal{G}) \quad (\text{avec } \text{sign}(0) = 0). \quad (20)$$

Ce qui change.

- **Pas de zéros exacts** : au voisinage de 0, le terme de fidélité et la pénalité s'équilibrent en un point $\neq 0$; le support de $\mathcal{G}$ reste plein. La parcimonie est un rétrécissement (*shrinkage*), pas une sélection.
- **Interaction avec Adam** : la pénalité passe par le préconditionneur $1/\sqrt{\hat{\mathbf{v}}}$; le rétrécissement effectif dépend donc de la variance du gradient de chaque coordonnée — un effet de bord connu (analogue au problème réglé par AdamW pour le weight decay) : le *même* β ne

produit pas la *même* contraction partout. Le schéma proximal (. II), appliqué hors du préconditionneur, n’a pas ce défaut.

- **Intérêt** : simplicité maximale (une ligne), et sert de contrôle expérimental — l’écart II vs III isole *l’effet du traitement de la non-lissité* à optimiseur identique.

9 Architecture IV — SGD à inertie + prox

Descente de gradient classique avec moment de Polyak :

$$\mathbf{u}_t = \mu \mathbf{u}_{t-1} + \mathbf{g}_t, \quad \theta_{t+1} = \theta_t - \eta \mathbf{u}_t, \quad \mu = 0.9, \quad \eta = \eta_0/2, \quad (21)$$

suivie de l’étape proximale (16). Le pas est réduit de moitié par rapport à Adam car, sans renormalisation par coordonnée, le pas stable est dicté par la *pire* courbure du paysage.

Ce qui change et ce que cela révèle. SGD applique le *même pas à toutes les coordonnées*. Sur un problème multilinéaire mal conditionné, cela force un compromis : pas assez grand pour faire progresser les directions plates (dictionnaires), pas assez petit pour ne pas osciller dans les directions raides (cœur). Expérimentalement, SGD suit Adam pendant la phase initiale (chute rapide portée par l’init SVD) puis *décroche* dans la phase de raffinement — l’écart final (≈ -0.3 à -0.6 dB selon la scène) mesure précisément la valeur du préconditionnement adaptatif. L’inertie ($\mu = 0.9$) atténue mais ne supprime pas ce déficit : elle accélère dans les vallées cohérentes mais n’égale pas les échelles.

10 Architecture V — LBFGS + prox

L-BFGS approxime l’inverse du hessien par une histoire de m paires $(\mathbf{s}_i, \mathbf{y}_i) = (\theta_{i+1} - \theta_i, \mathbf{g}_{i+1} - \mathbf{g}_i)$:

$$\theta_{t+1} = \theta_t - \eta \mathbf{H}_t \mathbf{g}_t, \quad \mathbf{H}_t \approx (\nabla^2 f)^{-1} \text{ (récurrence à deux boucles, mémoire } m = 10), \quad (22)$$

avec recherche linéaire interne (jusqu’à 20 évaluations de f par pas externe), puis étape proximale (16).

Ce qui change.

- **Information de courbure** : contrairement à Adam (diagonal), LBFGS capte des *corrélations entre coordonnées* — utile quand les blocs $\mathcal{G}$ et $\mathbf{D}_n$ interagissent fortement.
- **Coût par pas** : chaque pas externe vaut jusqu’à 20 passes avant/arrière ; à budget temps égal, LBFGS fait $\sim 20\times$ moins de pas. On le lance donc sur ~ 300 pas externes avec $\eta = 0.5$.
- **Friction théorique** : la théorie BFGS suppose f lisse ; l’étape proximale intercalée viole cette hypothèse (le prox déplace θ hors de la trajectoire prédite par $\mathbf{H}_t$). Avec β petit, la perturbation est négligeable ; pour β grand, un schéma *prox-quasi-Newton* dédié serait nécessaire.
- **Note d’implémentation** : l’implémentation PyTorch de LBFGS aplati les gradients par `.view(-1)`, ce qui exige des gradients *contigus* en mémoire — les gradients issus d’`einsum` ne le sont pas toujours ; ils sont explicitement rendus contigus dans la fermeture d’évaluation.

	I. ALS+FISTA	II. Adam+prox	III. Adam+ ℓ_1	IV. SGD+prox	V. LBFGS+
Mise à jour	alternée, exacte	simultanée	simultanée	simultanée	simultanée
Pas	calculé (Lipschitz)	adaptatif/coord.	adaptatif/coord.	global fixe	courbure m
Zéros exacts dans $\mathcal{G}$	oui (prox)	oui (prox)	non	oui (prox)	oui (prox)
Descente monotone	oui	non	non	non	non (recherche)
Hyperparamètres	β , rangs	+ η_0 , scheduler	+ η_0 , scheduler	+ η , μ	+ η , m
Coût/itération	élevé	faible	faible	faible	$\sim 20\times$ faible
Support GPU	partiel	natif	natif	natif	natif
Extension non-linéaire	re-dérivation totale	<i>immédiate</i>	<i>immédiate</i>	<i>immédiate</i>	délicate

Table 1: Les cinq architectures : même modèle (éq. 6), cinq stratégies de résolution.

11 Synthèse comparative

11.1 Tableau récapitulatif

11.2 Ce qui change d’une architecture à l’autre — lecture progressive

I $\rightarrow$ II (alternance $\rightarrow$ gradient simultané). Le changement le plus lourd de conséquences. L’ALS résout chaque bloc *exactement* dans le contexte figé des autres — optimal localement, mais la trajectoire alternée peut s’enfermer dans des points critiques médiocres où chaque bloc est optimal contre les erreurs des autres. Le gradient simultané fait des pas *imparfaits mais cohérents* : tous les paramètres co-évoluent, et le bruit de discrétisation aide à franchir les selles. Expérimentalement, cet unique changement vaut plusieurs dB à modèle identique — de loin l’écart dominant de l’étude, supérieur à ce que l’on gagne ensuite en changeant d’optimiseur au sein de la famille gradient.

II $\rightarrow$ III (prox $\rightarrow$ pénalité). Ne change ni la fidélité (à β faible) ni la vitesse ; change la *nature* de la parcimonie (exacte vs approchée) et sa *robustesse* (seuil hors préconditionneur vs rétrécissement modulé par $\hat{v}$). C’est un contrôle expérimental plus qu’une alternative.

II $\rightarrow$ IV (adaptatif $\rightarrow$ pas global). Supprime le préconditionnement diagonal ; mesure directement le coût du mauvais conditionnement multilinéaire. Le décrochage de SGD en phase de raffinement est la signature expérimentale de ce conditionnement.

II $\rightarrow$ V (diagonal $\rightarrow$ quasi-Newton). Ajoute des corrélations de courbure au prix de ~ 20 évaluations par pas. Sur ce problème, LBFGS égale Adam sans le dépasser : l’essentiel du conditionnement est *diagonal* (échelles par coordonnée), déjà capté par Adam ; la courbure croisée n’apporte pas de gain mesurable à budget égal.

11.3 Recommandations

1. **Pour une baseline de littérature** : architecture I — solveur canonique, garanties, zéro réglage ; c’est la référence attendue par les relecteurs.
2. **Pour la performance et l’extensibilité** : architecture II — meilleure fidélité, zéros exacts, GPU, et la boucle d’entraînement se transpose telle quelle aux modèles non-linéaires (seul le décodeur change).
3. **À reporter systématiquement ensemble** : I et II. Leur écart quantifie la part du solveur ; l’écart entre II et un modèle non-linéaire quantifie alors proprement la part de la classe de modèle. Confondre les deux écarts (comparer un non-linéaire optimisé par gradient à un linéaire résolu par ALS) surestime structurellement l’apport de la non-linéarité.

12 Détails d'implémentation

Produits de mode. La reconstruction (1) et ses dégradations sont réalisées par contractions `einsum(abc,ia,jb,kc->ijk)` ; l'autodiff fournit exactement (12) sans dérivation manuelle.

Double précision d'échelle. Les entrées sont normalisées par percentile 99 par source ; la sortie est dénormalisée par s_H et écrêtée à $[0, 1]$.

Arrêt. Budget maximal de 10^4 itérations, arrêt anticipé si la perte ne s'améliore plus de 10^{-7} pendant la patience ; l'état retenu est celui de la *meilleure perte* rencontrée (et non le dernier).

Suivi. À chaque 10 itérations sont journalisés la perte couplée et le taux de zéros exacts de $\mathcal{G}$ — ce dernier étant le diagnostic de santé du cœur (une sparsité qui dérive vers 100 % signale un seuillage pathologique).

Reproductibilité. Mêmes graines, mêmes opérateurs B_h, B_w, R (construits depuis la PSF et la SRF *fournies* par le cadre d'évaluation), même initialisation (8)–(9) pour les cinq architectures : la seule variable libre entre architectures est l'algorithme de descente.

13 Conclusion

Nous avons présenté cinq architectures de résolution d'un même modèle linéaire de fusion — la décomposition de Tucker couplée à cœur parcimonieux — en explicitant l'intégralité des équations de mise à jour et les conséquences de chaque choix algorithmique. Trois enseignements principaux se dégagent :

1. **Le solveur fait partie du modèle empirique.** À paramétrisation identique, le passage de l'alternance exacte au gradient simultané préconditionné change les performances de plusieurs dB : toute comparaison inter-modèles doit fixer le solveur ou reporter les deux.
2. **La parcimonie exige un traitement proximal.** Seul le seuillage doux — dans FISTA comme après Adam — produit un support creux exact ; la pénalité sous-différentiée ne fait que rétrécir. Le découplage du seuil et du scheduler est nécessaire pour que β garde un sens tout au long de l'entraînement.
3. **Le cadre gradient est le pont vers le non-linéaire.** La perte couplée, les opérateurs physiques différentiables, l'étape proximale et la boucle d'entraînement sont réutilisables à l'identique lorsque le décodeur multilinéaire (1) est remplacé par un décodeur convolutionnel : les architectures II–V constituent ainsi la base méthodologique commune des modèles non-linéaires du projet.

A Pseudo-code des deux schémas principaux

Algorithme 1 — Architecture I : ALS + FISTA

1. Initialiser $(\mathbf{D}_1, \mathbf{D}_2, \mathbf{D}_3, \mathcal{G})$ par (8)–(9).
2. **Pour** $i = 1, \dots, n_{\text{outer}}$:
 - (a) **Pour** $n = 1, 2, 3$: $\mathbf{D}_n \leftarrow$ solution de (11) ; normaliser les colonnes (7).
 - (b) $\mathcal{G} \leftarrow \mathcal{G} / \|\mathcal{G}\|_F$; calculer L par l'équation (13).
 - (c) **Pour** $j = 1, \dots, n_{\text{FISTA}}$: itération (14) avec seuil β/L .
3. **Retourner** $\mathcal{S} = \mathcal{G} \times_1 \mathbf{D}_1 \times_2 \mathbf{D}_2 \times_3 \mathbf{D}_3$.

Algorithme 2 — Architectures II/IV/V : gradient + prox (Adam / SGD / LBFGS)

1. Initialiser $\theta^{(0)}$ par (8)–(9).
2. **Pour** $t = 1, \dots, T$ **ou** arrêt anticipé :
 - (a) passe avant : normaliser les colonnes *dans le graphe*, reconstruire $\mathcal{S}$, dégrader, évaluer $f(\theta)$;
 - (b) rétropropagation ; écrêtage $\|\nabla\|_2 \leq 10$;
 - (c) pas de l'optimiseur (eq. 19, 21 ou 22) ;
 - (d) $\mathcal{G} \leftarrow S_{\beta\eta_0}(\mathcal{G})$ (seuil découplé du scheduler)
 - (e) mémoriser θ si f est la meilleure valeur rencontrée.
3. **Retourner** $\mathcal{S}(\theta^{\text{best}})$.